



# HOCHSCHULE COBURG

Hochschule für angewandte Wissenschaften Coburg  
Fakultät Elektrotechnik und Informatik

Studiengang: Informatik

Bachelorarbeit

## Geometriedekompression von Dreiecksnetzen auf der GPU

Janek Foote

Abgabe des Arbeit: 13.03.2024

Betreut durch:

Quirin Meyer, Hochschule Coburg

# Inhaltsverzeichnis

<b>Abbildungsverzeichnis</b>	<b>4</b>
<b>Codebeispielverzeichnis</b>	<b>5</b>
<b>1 Einführung</b>	<b>6</b>
1.1 Geschichtliche Ausarbeitung Thema Datenkompression . . . . .	6
1.2 Steigende Komplexität . . . . .	8
1.3 Ziel der Arbeit . . . . .	9
<b>2 Grundlagen</b>	<b>10</b>
2.1 Brotli Kompressionsstandard . . . . .	10
2.2 Parallele Datenverarbeitung . . . . .	10
2.3 Die traditionelle Rendering Pipeline . . . . .	13
2.3.1 Vertex Shader . . . . .	13
2.3.2 Tessellation Stage . . . . .	14
2.3.3 Geometry Shader . . . . .	14
2.3.4 Pixel Shader . . . . .	15
2.4 Compute Shader . . . . .	15
<b>3 Methodik</b>	<b>17</b>
3.1 Ablauf des Experiments . . . . .	17
<b>4 Mesh Shader</b>	<b>19</b>
4.1 Mesh Shading Pipeline . . . . .	19
4.1.1 Mesh Shader . . . . .	20
4.2 Meshlets . . . . .	20
4.3 Implementierung Mesh Shader . . . . .	21
4.4 Mesh Shader Implementation . . . . .	22
4.5 Lokale Vertex Buffer . . . . .	23
4.6 Das auf der GPU zu dekodierende Binärformat . . . . .	23
<b>5 Kompressionsstandard BrotliG</b>	<b>24</b>
5.1 LZ77 . . . . .	24
5.1.1 Kodierung eines Codewortes . . . . .	25
5.1.2 Dekodierung eines Codeworts . . . . .	25
5.2 Huffman Codierung . . . . .	26
5.2.1 Konstruktion einer Huffman Codierung . . . . .	27
5.3 GZIP . . . . .	28

5.4	Brotli-G Compute Shader . . . . .	28
5.5	CPU Ebene . . . . .	29
<b>6</b>	<b>Ergebnisse</b>	<b>30</b>
<b>7</b>	<b>Fazit</b>	<b>31</b>
7.1	j... . . . .	31
7.2	Ausblick . . . . .	31
	<b>Literaturverzeichnis</b>	<b>32</b>
	<b>Ehrenwörtliche Erklärung</b>	

## Abbildungsverzeichnis

Abb. 1:	Youtube Statistik . . . . .	7
Abb. 2:	SIMD Pattern . . . . .	12
Abb. 3:	traditionelle Rendering Pipeline . . . . .	13
Abb. 4:	Flussdiagramm Ablauf . . . . .	18
Abb. 5:	Mesh Shading Pipeline . . . . .	19
Abb. 6:	Huffman Code Beispiel . . . . .	28

## Codebeispielverzeichnis

Code 1:	Mesh Shader Main . . . . .	23
---------	----------------------------	----

# 1 Einführung

In der Computergrafik ist die Erzeugung eines Dreiecksnetzes eine gängige Methode zur Generierung von 3D-Modellen. Diese Modelle können in Topologie und Geometrie unterteilt werden. Für die Geometrie werden verschiedene Attribute benötigt. So werden die Positionen, die Normalenvektoren und Texturekoordinaten/Farbwerte für jeden Punkt des Dreiecksnetzes in single-precision floating point values (32 Bit Gleitkommazahlen) gespeichert. Für die korrekte Anordnung und Reihenfolge der Knotenpunkte ist die Topologie zuständig. Dabei ist die Datenkompression ein entscheidendes Thema. In einer Welt, in der digitale Daten schon lange ein wichtiges Thema sind, und dennoch immer weiter an Bedeutung gewinnen, ist die effiziente Speicherung und Übertragung ein wichtiger Gesichtspunkt. 3D Modelle werden so gut wie überall benötigt. Videospiele und Animationsserien wären ohne nicht vorstellbar. Architekten können ihre Ideen auch ohne Bleistift auf das Papier (oder den Bildschirm) bringen. Künstler wollen Modelle erschaffen, die den Eindruck gewinnen wollen, realitätsgetreu zu sein. Die Folge davon ist, dass diese Modelle stetig komplexer werden, und somit ein größerer Speicheraufwand benötigt wird. Um dem entgegenzuwirken, werden Methoden verwendet, diese digitalen Informationen zu komprimieren.

## 1.1 Geschichtliche Ausarbeitung Thema Datenkompression

Ursprünglich zur Repräsentation von Daten entwickelt, wurde der Morse Code zu einem der wichtigsten Werkzeuge für die Kommunikation des 19. Jahrhunderts. Bestehend aus zwei Grundbausteinen, einem kurzen und einem langen Signal, konnten einzelne Buchstaben kodiert werden. Erweitert man dieses Alphabet mit einem weiteren „Symbol“ einer Pause, die zwischen einzelnen Signalsequenzen eingelegt wird, können ganze Sätze übermittelt werden. Das bekannteste Werkzeug für den Morse Code ist der Telegraf, mit dem diese Signale über weite Strecken übertragen werden konnten. Die Erfindung des Morsecodes findet im 21. Jahrhundert nicht nur seinen Zweck in dramatischen Momenten des in Film und Fernsehens. Es war zeitgleich ein früher und großer Meilenstein und Wegbegleiter für die Kompression einer Datenquelle (in diesem Fall das Alphabet). Durch Untersuchungen einer großen Anzahl an Literatur kann eine Buchstabenhäufigkeit berechnet werden. Diese sagt aus, wie wahrscheinlich es ist, welcher Buchstabe in einem Text folgt, ohne den aktuellen Kontext, in Form von vorgehenden Buchstaben, zu betrachten. Da die Wahrscheinlichkeit eines Zeichens abhängig vom Alphabet ist, sollten diese nicht übergreifend verwendet werden. So sind die Buchstaben „E“ und „T“ die Buchstaben des englischen Alphabets, welche die höchste Auftrittswahrscheinlichkeit besitzen, während sich im deutschen Alphabet der Buchstabe „E“ von der Masse abhebt. Der Morse Code hat gezeigt, welchen Nutzen die Kompression von Information beinhaltet. Zu Kriegszeiten hat dieser eine effiziente und schnelle Übermittlung von Informationen ermöglicht. Dadurch konnte in

Krisenmomenten schnell reagiert werden, um so größeren Katastrophen frühzeitig abzuwenden, aber leider auch, solche zu verursachen.

### Der Ist-Stand

Springen wir in die heutige Zeit sehen wir die Auswirkung von komprimierten Daten. Die meisten Menschen denken an JPEGs und PNGs, wenn sie an digitale Bilder denken. Bekanntere Videoformate sind MP4, AVI und FLV. Bei all diesen Formaten handelt es sich um komprimierte Rohdaten. Das Filesystem eines jeden relevanten Betriebssystems komprimiert beim Speichern von Daten diese automatisch. Zusätzlich dazu besteht noch die Möglichkeit, seine Daten manuell zu komprimieren mithilfe von Programmen wie 7Zip, WinRar oder WinZip. Datenkompression kann in so gut wie allen Bereichen angetroffen werden. Und die Gründe dafür sind simpel. Speicherplatz ist teuer, und das Ressourcenmanagement wird deutlich vereinfacht, wenn die benötigte Hardware minimiert wird. Betrachten wir das Streamen von Daten auf dem Beispiel des größten Videostreaming Dienstes Youtube. Laut Statistiken werden pro Minute hunderte Stunden an Videomaterial hochgeladen Tendenz steigend (Abb. ). Um die Unmengen an Videos




Abb. 1: **Anzahl der Youtube Videos** Die Anzahl an Minuten die auf Youtube hochgeladen werden. Abbildung von Statista:

<https://www.statista.com/statistics/259477/hours-of-video-uploaded-to-youtube-every-minute/>

zu speichern, benötigt Google riesige Serverfarmen, die auf dem gesamten Globus verstreut sind. Eine genaue Zahl ist der Öffentlichkeit nicht bekannt, es steht jedoch außer Frage, dass diese

nochmal um einiges höher ausfällt, würde es keine Verfahren zur Datenkompression geben.

Ein weiterer Gesichtspunkt ist der eigentliche Nutzen von Youtube, dem Streamen von Videos. Um ein Video sehen zu können, muss dieses von dem Youtube Server, zum Nutzer, dem Client übertragen werden. Durch die Komprimierung der Quelldateien sind die zu übertragenden Daten schon geschrumpft. Es können jedoch noch weitere Schritte absolviert werden, um die Daten für den Nutzer besser zugänglich zu machen. Dazu werden Verfahren wie Transcoding, Transsizing und Transrating verwendet. Transcoding beschreibt den Prozess, ein bereits komprimiertes Videoformat in ein anderes, eventuell für den Client besser zugeschnittenes Videoformat zu komprimieren. Das sollte jedoch nicht zu oft angewendet werden, da die Qualität beim wiederholten dekomprimieren und komprimieren verloren geht, sollten die Verfahren verlustbehaftet sein.

In vielen Fällen kann die originale Auflösung vom Endgerät nicht abgespielt werden, und wird deshalb von diesem auf eine niedrigere Auflösung skaliert. Beispielsweise wenn das Endgerät lediglich 1080p auflösen kann, aber ein Video in 4K Auflösung gestreamt werden soll. Trotzdem werden die vollen Daten des Videoformats empfangen. Um diese Verschwendung von Bandbreite zu sparen, wird Transsizing verwendet. Die originalen Daten werden in eine kleinere Auflösung skaliert, und anschließend übertragen.

Um die Bitrate zu minimieren wird Transrating verwendet. So kann die Auflösung beibehalten werden bei jedoch geringere Bitrate. Die Verfahren zur Minimierung des Datenstroms hören sich zunächst sehr mächtig an, sind jedoch mit Vorsicht zu genießen. Der Vorgang ist nämlich Verlustbehaftet und kann bei zu starker Nutzung zu Artefakten führen. Dafür ermöglicht es jedoch Menschen, deren Internetzugang ein Abspielen in hoher Qualität nicht zulässt, den Streaming Anbieter zu nutzen.

Neben dem Beispiel von Streaming Anbietern reihen sich noch viele weitere Beispiele, die einen riesigen Vorteil von der Datenkompression ziehen. In einem jedem BWL Grundlagenfach wird die Wichtigkeit des Wettbewerbsvorteils vermittelt. Ein Unternehmen muss auf Marktveränderungen schnellstmöglich erkennen. Insbesondere Unternehmen im Finanzbereich sind davon abhängig, damit die Datenanalyse schnellstmöglich auf Kursschwankungen reagieren kann.

### 1.2 Steigende Komplexität

Um die Realität bestmöglich darzustellen, werden Modelle stetig detailreicher, wodurch die Anforderungen an der Hardware steigen. In einer komplexen Szene können mehrere Millionen Dreiecke sichtbar sein, die je nach Anwendung, in Echtzeit gerendert werden müssen. Der Wunsch nach realistischeren Modellen in der Animationsfilm und Videospielbranche hat die Dreiecksanzahl von 3D Modellen in die Höhe schießen lassen.



### 1.3 Ziel der Arbeit

Wie man Anhand der Geschichte sieht, war die Datenkompression in ihrer frühen Zeit ein wichtiges Tool, um Informationen zu weiterzugeben. Dennoch hat und wird sie immer größere Bedeutung finden. Durch die rasch zunehmenden Digitalisierung wurden sowohl Massenmedien, die zur Speicherung von Daten dienen und verbesserten Leitungen bis hin zu Glasfaserkabeln, die eine höhere Bandbreite ermöglichen, entwickelt. Die Unterhaltungsbranche hat sehr von der Entwicklung profitiert. Aber nicht nur in der Bereitstellung ihres Streaming Services haben Kompressionsmethoden eine Relevanz bei Anbieter wie Youtube, Netflix oder Disney+.

Besonders in westlichen Ländern ist die Firma Walt Disney der wohl bekannteste Herausgeber von Animationsfilmen und -serien. In früher Zeit wurden Disney Produktionen von Hand gezeichnet. Da das ein sehr mühseliger und langwieriger Prozess ist, wurde eine neue Technik verwendet, die die Effizienz und Produktionsgeschwindigkeit maßgeblich erhöht. Anstatt die Szene von Frame zu Frame zu konstruieren, und so Charaktere und Objekte aus neuen Positionen und Blickwinkeln ständig neu zu zeichnen, wurden die zu Beginn angesprochenen 3D-Modelle entworfen. Das hatte zudem zur Folge, dass Effekte, die schwer zu zeichnen waren, realistischer in Simulationen zu berechnen waren, wie z.B. die Welleneffekte im Wasser. Weitere Anwendungsfälle für 3D-Modelle in der Unterhaltungsbranche sind Videospiele, visuelle Effekte in Film und Fernsehen und in *Virtual-Reality* (VR) und 3D-Hologramme bei Shows und in Themenparks. 3D-Modelle sind auch in anderen Bereichen anzutreffen. Architekten können ihre Vorstellung visualisieren, und so den Auftragsgeber ein erstes Bild zur Inneneinrichtung geben. 3D Drucker können diese Modelle mit Kunststoff herstellen. In der Fertigung werden Modelle mittel CNC Fräse robuster hergestellt.

Eine gängige Repräsentation von 3D-Modellen ist die eines Dreiecksnetzes. Damit die 3D-Modelle möglichst nah an dem ist, das sich der Künstler vorgestellt hat, können diese Dreiecksnetze eine große Anzahl an Dreiecken besitzen. In dieser Arbeit soll der neuartige Kodierungsstandard BrotliG getestet werden. Ein beliebiges Dreiecksnetz wird dafür zunächst in viele, kleine mini-Dreiecksnetze zerteilt. Die sogenannten *Meshlets* werden in einem eigenen Format gespeichert, das anschließend von BrotliG auf der CPU komprimiert wird. Die GPU bekommt die Daten, und dekomprimiert jedes einzelne Meshlet, um das gesamte Mesh abschließend zu Rendern.

## 2 Grundlagen

Obwohl Dreiecksnetze eine effektive Darstellung bieten, 3D-Modelle darzustellen, beanspruchen diese sehr viel Speicherplatz. Mithilfe von Brotli-G sollen diese auf der CPU komprimiert, und auf der GPU dekomprimiert werden, sodass diese fertig zur Darstellung sind, ohne viel Bandbreite zu nutzen. Damit der Weg von Komprimierung zu Darstellung verständlich ist, müssen einige grundlegende Dinge geklärt werden.

In diesem Grundlagenkapitel werden die von Brotli-G genutzten Algorithmen erläutert. Zusätzlich wird ein Ausblick auf die Grafikpipeline gegeben, und die Stellen betrachtet, bei denen weitere Verbesserungen vorgenommen werden können. Diese zeigt alle Transformationen, die die Daten eines Dreiecksnetzes von dem GPU Buffer bis zum Bildschirm durchläuft.

### 2.1 Brotli Kompressionsstandard

Brotli-G ist eine Weiterentwicklung des Brotli Kompressionsstand, der von AMD im Jahre 2022 entwickelt und veröffentlicht wurde. Die AMD Spezifikation bietet parallele Datenverarbeiten nach dem SIMD Prinzip (Kap. 2) auf Parallelrechnern, wie GPUs und Multithreaded CPUs. Zum Verständnis des von AMD veröffentlichten Kompressionsmodells ist zunächst ein Blick auf das Original erforderlich.

Brotli ist ein von Google Research entwickelter Kompressionsstandard, der 2013 veröffentlicht wurde. Er ist darauf ausgelegt, Webinhalte effizienter zu komprimieren als ältere Standards wie Gzip oder Deflate. BrotliG wurde mit bedacht auf Kompatibilität mit dem offiziellen Brotli entwickelt. So sollte Brotli auch in der Lage sein, Inhalte, die mit BrotliG komprimiert wurden, zu entschlüsseln. Zu beachten ist, dass dies nur in diese Richtung funktioniert, und somit Brotli das BrotliG Format nicht dekodieren kann [Bro22].

Brotli verwendet eine Kombination vieler Kompressionsalgorithmen, um Inhalte effizient zu komprimieren. Brotli's Kern besteht aus einem LZ77 Algorithmus, der in unterschiedlichen Ausführung auch in anderen Kompressionsstandard verwendet wird. Der LZ77 Algorithmus wird zusätzlich mittels Huffman Codierung optimiert.

### 2.2 Parallele Datenverarbeitung

Michael Flynn unterteilte Rechnerarchitekturen in Kategorien, die Abhängig von der Anzahl der Instruktions- und Datenströme sind.

Die Instruktions- und Datenströme:

*SI* (**S**ingle **I**nstruction)

*MI* (**M**ultiple **I**nstruction)

*SD* (**S**ingle **D**ata)

*MD* (**M**ultiple **D**ata)

können kombiniert werden.

Dadurch ergeben sich die vier Rechnerarchitekturen *SISD*, *SIMD*, *MISD*, *MIMD*.

### **SISD (Single Instruction, Single Data)**

Die am häufigsten anzutreffende Rechnerarchitektur. Bekannter unter den Namen Von-Neumann Architektur bearbeitet diese Architektur die auf dem Speicher befindlichen Daten seriell. Man redet auch von skalaren Operationen auf die Daten. Rechnerarchitekturen mit SISD sind leicht zu verstehen und die Verarbeitung ist vorhersehbar. Der Preis dafür ist jedoch die langsame Geschwindigkeit gegenüber parallelen Architekturen.

### **SIMD (Single Instruction, Multiple Data)**

Um die Geschwindigkeit zu erhöhen, werden Daten, auf denen die selbe Operation ausgeübt wird, parallel verarbeitet. Das ist bei der Berechnung von Vektoren und Matrizen von Vorteil. Betrachten wir die Addition zweier Vektoren, so kann der resultierende Vektor berechnet werden, wenn die einzelnen Komponenten der Vektoren addiert werden (siehe Abb. 2). Der Vertex Shader macht von diesem Konzept Gebrauch, während dieser seine per-Vertex Operationen ausführt [DC96].

### **MISD (Multiple Instruction, Single Data)**

Um alle Kombinationen von Daten und Instruktionsströmen zu zeigen wurde auch MISD definiert. Die Rechnerarchitektur bezieht sich darauf, dass auf nur einem Datenpunkt verschiedene Operationen ausgeführt werden. Für eine lange Zeit war diese Art von Rechnerarchitektur rein theoretisch anzutreffen, da weder

### **MIMD (Multiple Instruction, Multiple Data)**

Wie auch die SIMD Architektur ist MIMD in Parallelrechnern anzutreffen. Das Operationsprinzip von MIMD ist die Datenparallelität. Das Funktionsprinzip von MIMD-Rechnern umfasst die




Abb. 2: **Parallele Addition von Daten** In der Abbildung ist eine Addition verschiedener Daten zu sehen. Da die selbe Operation ausgeübt wird können die einzelnen Komponenten parallel verarbeitet werden. Abbildung ist aus <http://ftp.cvut.cz/kernel/people/geoff/cell/ps3-linux-docs/CellProgrammingTutorial/BasicsofSIMDProgramming.html>

gleichzeitige Ausführung von Anweisungen durch mehrere Prozessoren, die entweder über gemeinsame Variablen oder durch Nachrichten miteinander kommunizieren [DC96]. TODO später [JBG17]

## 2.3 Die traditionelle Rendering Pipeline

Um den Nutzen der neu vorgestellten Task- und Mesh-Shader Pipeline zu verstehen, muss zunächst die traditionelle Pipeline dort betrachtet werden, wo sie verbessert werden kann. Die Rendering Pipeline besteht aus eine Reihe von programmierbaren (Abb. 3 grün dargestellt) und fixed-function (Abb. 3 türkis dargestellt) Stages. Dazu kommt, dass einige dieser Stages optional sind.




Abb. 3: **traditionelle Rendering Pipeline**

Die Abbildung beschreibt den Verlauf durch die einzelnen Shader Stages, die jeder Vertex macht. Entnommen wurde diese aus dem NVidia Blogpost [Kub18]

Im GPU Memory angekommen, liest die *Vertex Attribute Fetch* Stage die Vertex Daten aus, und sendet diese an den Vertex Shader. Die Vertex Daten werden dort in die benötigten Koordinatensysteme transformiert und der optionalen Tessellation Stage weitergegeben, falls diese verwendet wird. Die Tessellation Stage ist dazu da, Patches von Primitiven in kleinere Primitiven zu unterteilen. Der optionale Geometry Shader kann dazu verwendet werden, weitere Vertices zu generieren. Im Rasterizer angekommen, werden Primitiven verarbeitet und daraus Fragmente berechnet, denen der Fragment Shader zum Abschluss ihre Farbe gibt.

Im Folgenden werden die einzelnen Stages nochmal genauer erläutert.

### 2.3.1 Vertex Shader

Zunächst wird der vom Entwickler programmierbare Vertex Shader angesteuert. Dieser ist nicht optional, da alles nachfolgende auf den ausgegebenen Vertices aufbaut. Hier können Operationen auf einzelnen Vertices ausgeführt werden. Dafür wird der Vertex Shader für jeden Vertex einzeln aufgerufen. Hier zeichnet sich das SIMD Modell der GPU aus (Kap 2.2), da der Vertex Shader von mehreren Prozessoren auf unterschiedlichen Vertices zeitgleich operiert. Die Inputs des Vertex Shaders werden mittels *Vertex Attribute Locations* in den Shader eingebunden. Der Shader kann dadurch die Positionen, Normalen und Texturkoordinaten von der CPU aufnehmen. Eine Einschränkung, die dabei aufkommt, ist das Verhältnis von Eingabe und Ausgabe Vertices. Der Shader erwartet, dass für jeden Eingabe Vertex auch ein Vertex ausgegeben wird. Die Vertex Position wird für gewöhnlich in den Clip-Space transformiert, und der Pipeline weitergegeben.

### 2.3.2 Tessellation Stage

Die Ausgabe Vertices des Vertex Shaders gelangen anschließend in die optionale Tessellation Stage. Der generelle use-case ist, einen Patch an Primitiven in wiederum kleinere Primitiven zu verarbeiten. Die Tessellation Stage wird in drei Schritte unterteilt. Darunter ist mit dem *Tessellation Control Shader* (TCS) ein optional programmierbarer Schritt, eine fixed-function mit der *Primitive Generation* und einen programmierbaren *Tessellation Evaluation Shader* (TES).

#### Tessellation Control Shader (TCS)

Der *Tessellation Control Shader* (TCS) (der wiederum optional ist), ist ein geeigneter Schritt um das *LOD* (Level of Detail) zu berechnen und unter gewissen Voraussetzungen vorab einige Patches zu cullen. Ein Patch beschreibt eine Anzahl an Primitiven. Aus der Subdivision dieses Patches werden weitere Vertices berechnet, die zur Verarbeitung in den nächsten Schritt der Pipeline geschickt werden. Im TCS wird der Grad der Tessellation, das Spacing zwischen subdivided Punkten und die gewünschte Topologie festgelegt. Genauer gesagt wird hier gesetzt, wie oft die Primitiven unterteilt werden und welche Form diese am Ende haben sollen (triangle, quad, isolines).

#### Tessellation Topology Generation (TPG)

Mit der fixed-function stage des Tessellation Schritts werden die Primitiven mittels den im TCS bestimmten Parametern unterteilt. Die Koordinaten werden anschließend für den Tessellation Evaluation Shader berechnet. Diese unterteilt die Patches abhängig von den Berechnungen der TCS.

#### Tessellation Evaluation Shader (TES)

Der *Tessellation Evaluation Shader* hat den einfachsten Job und realisiert lediglich die Arbeit, die von den zwei vorherigen Stages verrichtet wurde. Die berechneten Koordinaten des TPG werden in dieser Shader Stage interpoliert, um die neuen Vertices zu generieren. Abschließend werden die aus der Subdivision berechneten Vertices ausgegeben. Wenn der optionale TCS nicht genutzt wird, werden default Parameter für den TPG benutzt. [CR12][Car22]

### 2.3.3 Geometry Shader

Ein weiterer optionaler Schritt in der traditionellen Grafikpipeline ist der *Geometry Shader*. Er bekommt eine Primitive als Input, und kann keine oder auch mehr Primitiven ausgeben, als er

bekommen hat. Die Fähigkeit zusätzliche Vertices zu generieren ist auch das, was den Geometry Shader besonders macht. Der Geometry Shader bekommt seinen Input entweder vom TES, oder, wenn die Tessellation Stage keine Verwendung findet, vom Vertex Shader und leitet seine Ausgabe an den Fragment Shader weiter. Um Bandbreite zwischen CPU und GPU zu sparen, kann ein Geometry Shader ein Dreiecksnetz mit wenigen Dreiecken erweitern und dieses so detaillierter gestalten. Ähnlich wie bei der Tessellation, die auf *Patches* von Primitiven agiert, verarbeitet der Geometry Shader die Primitiven an sich.

### 2.3.4 Pixel Shader

Der Pixel bzw. Fragment Shader ist der letzte programmierbare Schritt der Grafikpipeline. In diesem werden die transformierten Vertices und Primitiven schlussendlich gezeichnet. Der Pixel Shader operiert jedoch nicht auf diesen Daten, sondern auf sogenannten *Fragmenen*. Das bedeutet, bevor der Pixel Shader seinen Input bekommt, müssen Vertices und Primitiven erst durch den Rasterizer. Nun liegt es am Entwickler, den einzelnen Fragmenten ihre Farbe zu geben. In einem Modell werden per-Vertex Texturkoordinaten gesetzt, die auf eine Texturemap verweisen. Im Fragment Shader wird diese Texturemap mittels Sampler interpoliert. Zusätzlich müssen noch Materialeigenschaften beachtet werden. Alternativ kann jeder Vertex auch seinen eigenen Farbwert besitzen.

Um der Szene mehr Realismus beizusteuern, kann im Fragment Shader auch ein Lichtmodell implementiert werden. Beispiele dafür sind *Flat shading*, *Gouraud shading* und *Phong shading*. Für die Lichtberechnung werden die Oberflächen-Normalen benötigt. Diese sind entweder in einem Dreiecksnetz gegeben, oder müssen noch berechnet werden. Ausgabe des Pixel Shaders ist wiederum ein Fragment.

## 2.4 Compute Shader

Der Compute Shader gehört nicht zur traditionellen Grafikpipeline, kann darin aber seinen Nutzen finden. Sie dienen dazu, jede Mögliche Information die gewünscht ist auf der GPU zu berechnen. Anders als bei den Shader Stages der traditionellen Grafikpipeline (Kap. 3), erwartet der Compute Shader keine definierten Input/Output Daten, wie beispielsweise der Vertex Shader, der als Input und Output einen Vertex erwartet. Der Compute Shader kann also willkürliche Daten verarbeiten und dabei noch die Parallelisierung der GPU nutzen [Com24].

Wie schon gesagt erhält der Compute Shader keine Input Variablen wie beispielsweise der Vertex Shader. Im Gegensatz zu diesem werden benötigte Daten mittels Buffer und „Shader Ressource

Views“ auf die GPU geladen (in D3D12). Aber ganz ohne Inputs kommt der Compute Shader nicht aus. Vor Aufruf des Compute Shaders muss bestimmt werden, mit wie vielen Threads dieser arbeiten soll. Der Aufruf der Dispatch Methode mittel Grafik API führt dazu, das der aktuell aktive Compute Shader aufgerufen wird. Die Dispatch Methode nimmt die Anzahl an Threads in drei Dimensionen als Argument.

Dafür gelten jedoch Hardware Limitierungen. Für die Anzahl der Threads muss gelten

$$\begin{aligned} numThreadsX, numThreadsY, numThreadsZ &\leq 128 \\ numThreadsX * numThreadsY * numThreadsZ &= 1024 \end{aligned}$$

(Für Compute Shader Version 5\_0)

Um das SIMD Konzept des Compute Shaders zu verstehen sind zwei Variablen elementar wichtig. SVGroupThreadID und SVGroupID. TODO



## 3 Methodik

Die vorliegende Bachelorarbeit beschäftigt sich mit der Dekodierung verschiedener Dreiecksnetze mittels dem Kodierungsstandard Brotli-G. Diese Methodiksektion dient dazu, einen detaillierten Einblick auf die Durchführung und Analyse des Experiments zu geben. Das Experiment zielt darauf ab, komprimierte Dreiecksnetze auf der GPU zu dekomprimieren. Insbesondere sollen das Kompressionsverhältnis, Dekompressionsgeschwindigkeit und die visuelle Qualität quantitativ ausgewertet werden.

### 3.1 Ablauf des Experiments

In diesem Abschnitt folgt eine kleine Beschreibung, wie die Kompressionspipeline aussieht. In den Folgenden Kapiteln werden die einzelnen Teilschritte genauer erläutert.

Zu Beginn muss der Datensatz mittels Brotli-G kodiert werden. Der Einfachheit halber wird in diesem Abschnitt von einem einzigen Dreiecksnetz gesprochen. Der Meshoptimizer von Zeux [Zeu] ist dafür verantwortlich, aus den Positionen und Indizes die Meshletdaten zu generieren. Dazu wurde ein Binärformat entworfen, welches die relevanten Daten zum Darstellen des gesamten Dreiecksnetzes speichert. Das Binärformat besteht dementsprechend aus dem Meshlet Descriptor, Vertex Ressourcen (Positionen und Normalen) und den Indizes zur Primitivengenerierung.

Dieses Binärformat wird als gesamtes komprimiert. Anschließend werden die GPU Ressourcen für die Eingabe (komprimiertes Dreiecksnetz) und Ausgabe (dekomprimiertes Dreiecksnetz) angelegt.

Für die Ausgabe wird eine „Unordered Access View (UAV)“ verwendet. Wie der Name schon vermuten lässt, bietet diese eine flexiblere Möglichkeit, gleichzeitig an verschiedenen Orten zu lesen und schreiben. Besonders von Vorteil ist dieser Ressourcentyp für die parallele Verarbeitung. So können einzelne Threads von der Ressource lesen/schreiben, ohne darauf warten zu müssen, bis ein anderer Thread die Ressource wieder freigibt [Mic21].

Die UAV wird im Compute Shader als Output Buffer gesetzt, und mit den dekomprimierten Daten des Dreiecksnetzes gefüllt. Abschließend wird die UAV im Mesh Shader gesetzt und die Meshlets und somit das gesamte Dreiecksnetz werden aus den Binärdaten rekonstruiert.

Der gesamte Vorgang ist in Abbildung 4 zu sehen.

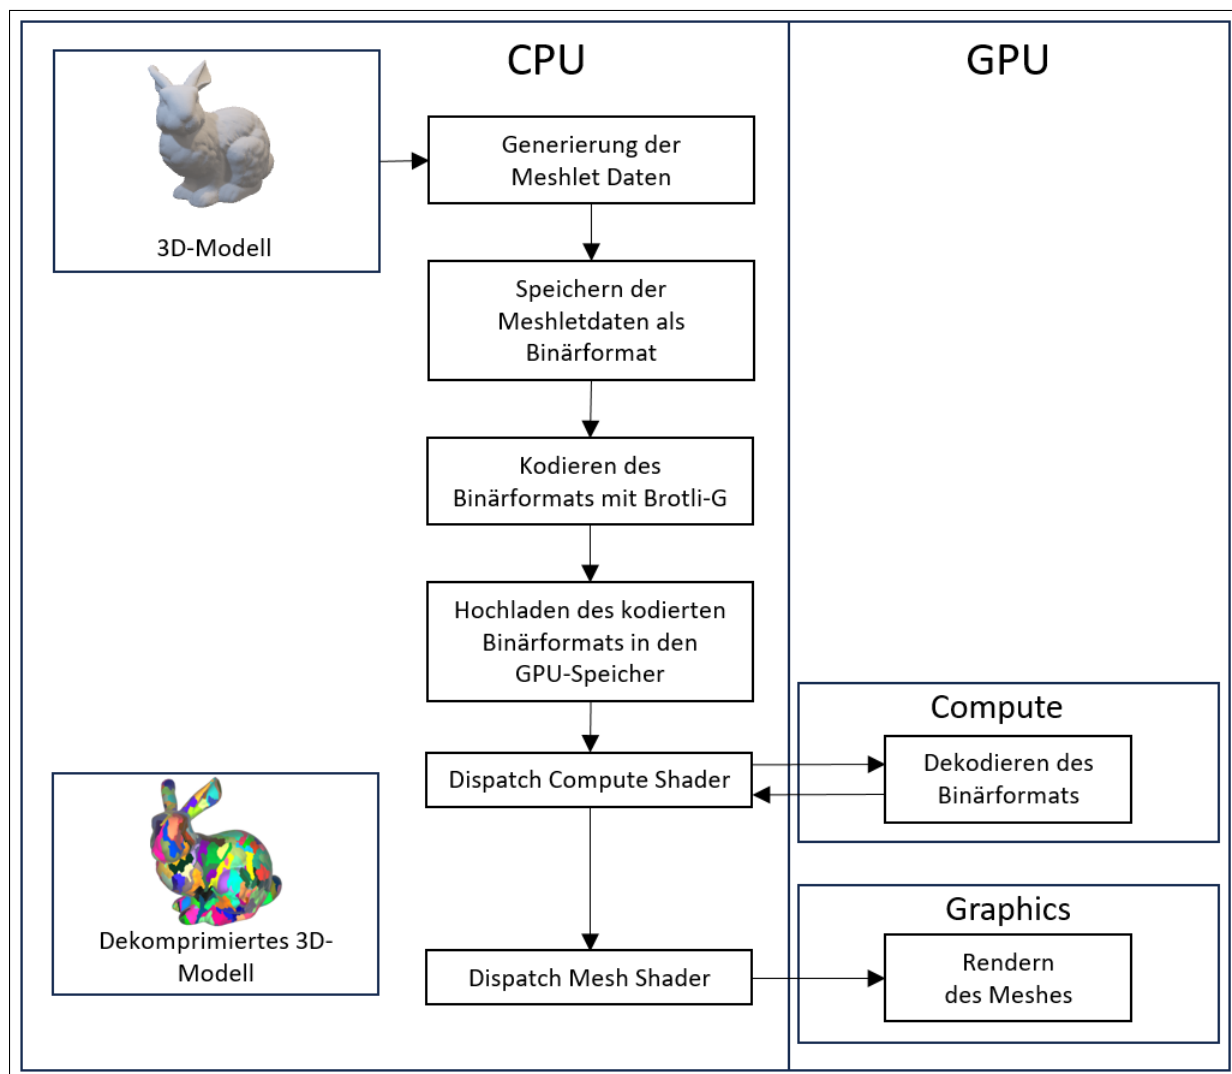


Abb. 4: **Flussdiagramm Ablauf** Abbildung der Dekompressionspipeline.

## 4 Mesh Shader

Die Architektur, auf der die neuartigen RTX-GPUs von Nvidia aufbauen, erweitert die Möglichkeiten, wie die Parallelisierung von GPUs genutzt werden kann. Mit der GeForce RTX 20er Serie wurden die ersten GPUs mit der Turing Architektur veröffentlicht, die sich auch an Privatpersonen richtet. Als großer Verkaufspunkt wurde bereits früh mit den Möglichkeiten von Real-time Raytracing und Deep Learning durch Tensor Core geworben [Bur20]. Eine wesentliche Änderung an der Grafikkipeline wird jedoch bis heute noch relativ wenig Beachtung geschenkt. Mit dem Shader Model 6 hat NVidia ihre sogenannte "next-generation shading Pipeline" vorgestellt. Damit wird eine Alternative zur traditionellen Shading Pipeline gestellt, die dem Entwickler mehr Freiheit überlässt, die Parallelisierbarkeit der GPU zu nutzen. Der Mesh Shader hat die Eigenschaften des Compute Shaders 2.4, der Daten auf der GPU parallel verarbeiten kann. Auch Geometrie Daten können mithilfe des Compute Shaders berechnet werden, jedoch ist der Compute Shader kein Teil der traditionellen Grafikkipeline und findet dadurch seinen Nutzen auch außerhalb des Renderings [Ile22]. Mit der *Mesh Shading Pipeline* wurde die Möglichkeit der Parallelisierung des Compute Shaders mit der neuen Rendering Pipeline verknüpft. Anders als bei der herkömmlichen Grafikkipeline erhält der Mesh Shader seine Daten direkt vom Speicher. Dadurch öffnen sich Türen für den Entwickler, da er komprimierte Daten direkt in den GPU Speicher laden kann, um die Daten dann effizienter auf dieser zu dekomprimieren.

### 4.1 Mesh Shading Pipeline

Die Mesh Shading Pipeline wirft einige Shader Stages der traditionellen Grafikkipeline aus Kap. 2.3 raus, und bietet die Funktionalitäten in den neuen Task- und Mesh Shadern an.




Abb. 5: **Mesh Shading Pipeline** Abbildung der Mesh Shading Pipeline. Die Abbildung ist aus dem NVidia Blogpost [Kub18]

Wie in der Abbildung 5 zu sehen ist, durchlaufen die Vertex Daten in der Mesh Shading Pipeline zunächst den Task Shader. Ähnlich wie bei Compute Shadern (Kap. 2.4), werden hier die Anzahl der workgroups an den Mesh Shader versendet. Der Mesh Shader arbeitet auf Threads. Die Ein- und Ausgabe des Mesh Shaders werden vom Entwickler festgelegt. So können wie beim Compute Shader auch arbeiten verrichtet werden, die nicht direkt fürs Rendering wichtig sind. In dieser

Arbeit wird der Mesh Shader zum dekomprimieren des Dreiecksnetzes genutzt. Zum Rendern müssen jedoch wieder Fragments ausgegeben werden, die in den unveränderte Rasterization und Pixel Shader Stages verarbeitet werden. [Kub18]

### 4.1.1 Mesh Shader

Da die optionale Task Shader Stage in dieser Arbeit nicht verwendet wird, betrachten wir die Pipeline aus dem Szenario, das die Workgroups der DX12 Methode direkt an den Mesh Shader dispatched werden. Die Nummer an Workgroups Eine Workgroup Eine Workgroup besteht arbeitet mit *Shared Memory*.

## 4.2 Meshlets

Um die neuartigen Shader für das Rendering zu verwenden, wird empfohlen, das gesamte Mesh in kleinere Subsets, sogenannte Meshlets, zu unterteilen. Die traditionelle Grafikpipeline verarbeitet die Daten des Dreiecksnetzes in serieller Manier. Dadurch kommt es jedoch zu Bottlenecks. In der traditionellen Pipeline werden Vertex und Primitiven zugeschnitten und in kleine Clustern verarbeitet. Dazu wird der Primitive Distributor vor der Vertex Shader Stage aufgerufen. Dieser liest die Daten des Index Buffers und generiert dementsprechend möglichst performant diese Cluster an Daten. Der Schritt des Primitive Distributor ist jedoch eine fixed-function Stage der Grafikpipeline, wodurch der Entwickler keinen direkten Zugriff hat. Das hat zur Folge, dass die Cluster nicht auf die Bedürfnisse des Entwicklers und dessen Implementierung angepasst werden können. Zuzüglich werden die Cluster zu jedem Frame, bzw. vor jedem Aufruf der Pipeline neu generiert. Dieser Schritt ist redundant, sollte das Dreiecksnetz zur Laufzeit unverändert bleiben [Car22], [Kub18].

Durch die Compute Shading Natur des Mesh Shaders ist der Input der Daten nicht mehr festgelegt wie bei der traditionellen Pipeline. Dadurch kann der Entwickler seine eigenen Implementationen zur Generierung von Meshlets verwenden. Anders als bei der herkömmlichen Grafikpipeline werden Meshlets auf CPU Ebene erstellt. Dazu werden Vertex Positionen und Indizes benötigt. Die Anzahl der Vertices und Primitiven muss im Vorfeld festgelegt werden. Die Auswahl der Meshletgröße ist abhängig von der verwendeten GPU. So wird im NVidia Blogpost „Introduction to Turing Mesh Shaders“ eine maximale Anzahl an Vertices von 64, und Primitiven von 126 empfohlen. Es werden 126 statt 128 Primitiven empfohlen, da 4 Byte für die Anzahl der Primitiven verwendet werden, die im selben Block Speicher enthalten sein sollen, bzw. keinen weiteren Block beanspruchen sollen [Kub18]. Arseny Kapoulkine hat verschiedene Meshletgrößen miteinander verglichen. Er ist zu dem Schluss gekommen, dass 64 Vertices und

84 Primitives am effizientesten ist, insbesondere dann, wenn im Task Shader Culling an den einzelnen Meshlets betrieben wird. Des weiteren ist die Empfehlung des Blogposts nach eigenen Tests zwar ein guter Maßstab, jedoch wird im Durchschnitt viel Speicher des Primitiven Buffers ungenutzt bleiben, da die 126 Primitiven mit 64 Vertices nie erreicht werden [Kap23].

### 4.3 Implementierung Mesh Shader

Wie im vorherigen Unterkapitel angekündigt muss das Dreiecksnetz auf der CPU zu Meshlets geschnitten werden. Dazu wurde in dieser Arbeit der Meshoptimizer von Zeux verwendet [Zeu]. [Implementierung von Zeux beschreiben] Die Funktion „meshopt\_buildMeshlets“ nimmt als Eingabeparameter die maximale Anzahl an Vertices und Primitiven (Kap.4.2), die Vertex und Index Daten sowie drei leere Buffer. Der Buffer *meshlet\_indices* wird die neuen Index Daten enthalten, mit denen die Primitiven berechnet werden können. Der *meshlet\_vertices* Buffer beinhaltet die einzigartigen Vertices des Dreiecksnetzes (Kap ??). Der letzte Buffer wird in dieser Arbeit als *Meshlet Descriptor* bezeichnet. Der Einfachheit halber wird er im Code jedoch einfach als *meshlets* implementiert. Der Meshlet Buffer setzt sich auch folgenden Elementen zusammen

- Vertex Count: Die Anzahl der Vertices  $V$  in dem Meshlet mit dem Index  $i$
- Primitive Count: Die Anzahl der Primitives  $P$  in dem Meshlet mit dem Index  $i$
- Vertex Offset: Die Menge an Schritten im Vertex Buffer, um an die Vertices des  $i$ -ten Meshlets zu gelangen
- Primitive Offset: Die Menge an Schritten im Index Buffer um an die Primitives des  $i$ -ten Meshlets zu gelangen

Mit den Informationen der originalen Vertexdaten und der drei neu generierten Buffer *meshlet\_indices*, *meshlet\_vertices* und *meshlets*, kann nun der Mesh Shader gefüttert werden. Zunächst müssen die während des Build-Vorgangs kompilierten Shader gelesen werden. Diese enthalten Informationen zum Layout der Root Signature, die daraufhin per API-Call erstellt wird. Bevor die Meshlet Daten an den Mesh Shader übergeben werden können, müssen diese in einen GPU Buffer geschrieben werden, damit diese anschließend in den GPU RAM geschrieben werden können. Wenn das alles gemacht ist können in der Commandlist der Constant Buffer und die benötigten Meshletdaten über die DirectX12 API-Calls `SetGraphicsRootConstantBuffer` und `SetGraphicsRootShaderResourceView` gesetzt werden.

## 4.4 Mesh Shader Implementation

Im Codeabschnitt 1 ist ein einfacher Mesh Shader zu sehen. Im Mesh Shader wird die Root Signature entsprechend den Anforderungen gesetzt. Minimal wird ein StructuredBuffer für jeden der auf der CPU generierten Meshlet Buffer benötigt. Um dem Endresultat 3-Dimensional wirken zu lassen, wird ein ConstantBuffer verwendet, der die *model*, *modelView* und *modelViewProjection* Matrix beinhaltet. Zusätzlich dazu nimmt der Constant Buffer noch ein boolean, um zu steuern, dass die Meshlets farbig hervorgehoben werden. Zunächst wird das aktuelle Meshlet aus dem *Meshlet Descriptor Buffer* genommen. Die *SV\_GroupID* stellt in dieser Implementierung den aktuellen Index der Meshlets dar. Um den lokalen Index des aktuellen Meshlets zu bekommen, muss die *SV\_GroupThreadID* verwendet werden. Die aktuelle GroupID wird in einzelne Threads unterteilt, damit die GPU sich bei der parallelen Verarbeitung nicht in die queere kommt. Die Anzahl der Threads wird mittels `[NumThreads(128, 1, 1)]` im Mesh Shader, oder, falls vorhanden, im Task Shader festgelegt.

```
[RootSignature(ROOT_SIG)]
[NumThreads(128, 1, 1)]
[OutputTopology("triangle")]
void main(
    in uint gtid : SV_GroupThreadID,
    in uint gid : SV_GroupID,
    out vertices VertexOut verts[64],
    out indices uint3 tris[84]
)
{
    Meshlet m = Meshlets[gid];
    uint3 primitive;

    SetMeshOutputCounts(m.VertCount, m.PrimCount);

    if (gtid < m.PrimCount)
    {
        primitive = GetPrimitive(m, gtid);
        tris[gtid] = primitive;
    }

    if (gtid < m.VertCount)
    {
        uint vertexIndex = GetVertexIndex(m, primitive[0]);
        verts[gtid] = GetVertex(gid, vertexIndex);
    }
}
```

Code 1: Mesh Shader Main

### 4.5 Lokale Vertex Buffer

### 4.6 Das auf der GPU zu dekodierende Binärformat

[Eventuell nicht als eigenes Unterkapitel]

## 5 Kompressionsstandard BrotliG

asdfasdf

### 5.1 LZ77

Der LZ77 (*Lempel-Ziv77*) Algorithmus gehört zu der Gruppe der Phrasenkodierung und ist ein verlustfreier, auf einem Wörterbuch basierender Algorithmus. Der Algorithmus komprimiert sequentielle Zeichenketten. Dabei kann dieser auf jeder Art von Daten, egal wie der Inhalt und die Größe aussieht, angewendet werden. Ob es sich lohnt, diesen anzuwenden, ist jedoch von den Daten abhängig. Beispielsweise sind Bilder ein schlechter Anwendungsfall, da sich die Informationen nur im Ausnahmefall wiederholen, und es deutlich bessere Kompressionsalgorithmen zur Komprimierung dieser gibt. Das Ziel des LZ77 Algorithmus ist lediglich, redundante Informationen zusammenzufassen.

Bevor der Algorithmus beschrieben wird, werden die benötigten Elemente definiert:

1. Eingabestrom: Die zu kodierenden Daten
2. Symbol: Ein willkürlich gewähltes Element des Eingabestroms
3. Datenfenster: Alle Symbole vom Start des Eingabestroms bis zum aktuell betrachteten Symbol
4. Vorschauenfenster: Ein Buffer fester Größe der Symbole vom aktuell betrachteten Symbol bis zum Ende des Buffers enthält
5. Schiebefenster: Daten- und Vorschauenfenster
6. Codewort: Ein Codewort bestehend aus dem Offset, der Lauflänge und des zu kodierenden Symbols

Der Ablauf des Algorithmus besteht aus folgenden Schritten:

Zu Beginn des Algorithmus wird das Datenfenster auf den Start des Eingabestroms gesetzt. Dieses Fenster ist zunächst leer. Das Vorschauenfenster wird vom Start des Eingabestroms mit Symbolen gefüllt, bis dieses voll ist. Zunächst wird das erste Symbol kodiert. Dafür verwendet der LZ77 Algorithmus ein Tupel in der Form von (*Position*, *Lauflänge*) und abschließend das zu kodierende Symbol. Dem Wörterbuch noch nicht bekannt Symbole werden neue Symbole mit (0, 0)Symbol hinzugefügt. Nach jedem Schritt wird das Schiebefenster um die Lauflänge der kodierten Symbole im Eingabestrom verschoben [Mic23].



Datenfenster	Vorschaufenster	restliches Codewort	Kodierung
	laufen	raufen	(0, 0)l
l	aufenr	aufen	(0, 0)a
la	ufenra	ufen	(0, 0)u
lau	fenrau	fen	(0, 0)f
lauf	enrauf	en	(0, 0)e
laufe	nraufe	n	(0, 0)n
laufen	raufen		(0, 0)r
aufenr	aufen		(6, 4)n

### 5.1.1 Kodierung eines Codewortes

Zur Veranschaulichung wird das Codewort „laufenraufen“ mit dem LZ77 Algorithmus kodiert und anschließend wieder dekodiert. Daten- und Vorschaufenster haben in diesem Beispiel eine Kapazität von jeweils sechs Symbolen.

Eine Besonderheit die zunächst nicht intuitiv ist, ist die Konstruktion des letzten Codewortes in diesem Beispiel. Die Symbolsequenz „aufen“ mit der Kodierung  $6, 4)n$  könnte auch mit einem Offset von fünf kodiert werden. Im Normalfall würde die Symbolsequenz auch so kodiert werden. Da jedoch das Symbol „n“ das letzte Symbol des zu kodierenden Worts ist, und es so kein weiteres, zu kodierendes Symbol gibt, muss die Länge um eins reduziert werden, und das letzte Symbol kodiert werden.

Aus dem Beispiel geht hervor, dass die Auswahl der Buffergröße gut gewählt werden muss, damit der Algorithmus effektiv verwendet werden kann. Wäre in dem Beispiel das Datenfenster lediglich Platz für vier statt fünf Symbole, hätte die Symbolsequenz „aufe“ nicht als ganzes kodiert werden können. Die weiteren Iterationen der Lempel-Ziv Algorithmen haben statt einem lokalen Wörterbuch (Datenfenster) ein globales Wörterbuch verwendet. Durch die große Anzahl an Vergleichen erreicht der LZ77 Algorithmus ein besseres Kompressionsverhältnis als der LZ78 Algorithmus, benötigt für die Kompression jedoch länger. Wie lange das Komprimieren der Daten dauert ist jedoch nicht wichtig für diese Arbeit. Der interessante Punkt ist die Dekompressionsgeschwindigkeit. Der LZ77 Algorithmus ist bedeutend schneller bei der Dekomprimierung als bei der Komprimierung [CPP15].

### 5.1.2 Dekodierung eines Codeworts

In diesem Abschnitt soll aus der Kodierung wieder das zuvor festgelegte Codewort generiert werden.

Kodierung	Datenfenster	Codewort
(0, 0)l		l
(0, 0)a	l	la
(0, 0)u	la	lau
(0, 0)f	lau	lauf
(0, 0)e	lauf	laufe
(0, 0)n	laufe	laufen
(0, 0)r	laufen	laufenr
(6, 4)n	aufenr	laufenraufen

Wie zu sehen ist, ist der LZ77 Algorithmus sowohl leicht verständlich als auch effektiv, wodurch er seinen Nutzen in vielen Anwendungen findet. Seine Weiterentwicklungen nennen sich LZ78 und LZW, die zwar dem LZ77 Algorithmus technisch überlegen sind, aufgrund von Patenten jedoch nicht so eine große Rolle spielen wie die erste Iteration von Lempel und Ziv. In Kombination mit anderen Techniken wie der Huffman Codierung bildet der LZ77-Algorithmus jedoch die Grundlage vieler leistungsstarker Kompressionsstandards, die heute in vielen Applikationen zu finden sind [QUELLE!!!].

## 5.2 Huffman Codierung

Eine gewisse Ähnlichkeit zu dem in der Einleitung angerissenen Thema des Morse Codes enthält die von Brotli verwendete Huffman Codierung. Die Huffman Codierung ist eine Methode zur verlustfreien Datenkompression und gehört zur Art der Codewort basierten Entropiekodierung. Ähnlich wie beim Morse Code, werden Symbole durch Bitfolgen substituiert. Was beim Morse Code als langes und kurzes Signal galt, ist im Huffman Code eine 0 oder 1. Mit der Huffman Codierung werden häufig auftretende Symbole durch kurze Bitfolgen dargestellt. Dementsprechend erhalten Symbole mit geringer Auftrittswahrscheinlichkeit ein langes Codewort. Bei der Betrachtung des Morse Codes fällt auf, dass nicht jeder Buchstabe die selbe Anzahl an Signalen beansprucht. Die Codewörter im Morse Code haben sich nämlich ebenfalls die Eigenschaft der Auftrittswahrscheinlichkeiten zunutze gemacht. Die im englischen Alphabet meist verwendeten Codewörter „E“ und „T“ werden beide mit jeweils einem Signal dargestellt. Das „E“ wird mit einem kurzen, während das „T“ vom langen Signal dargestellt wird. Mithilfe dieser Eigenschaft verbrauchen Symbole, die häufig auftreten, weniger Platz im Bitstrom [Mof19]. Histogramm ....

### 5.2.1 Konstruktion einer Huffman Codierung

Zur Konstruktion eines Huffman Codes wird ein Binärbaum generiert. Die zu kodierenden Symbole werden als Blätter des Baumes betrachtet. Der Baum wird sozusagen von „unten nach oben“ aufgebaut. In jedem Schritt werden die zwei Symbole oder Knoten mit der geringsten Auftrittswahrscheinlichkeit zu einem neuen Knoten verbunden. Die Auftrittswahrscheinlichkeit des neu erstellten Knotens ist die Summe der verbundenen Symbole/Knoten. Sobald die Wurzel des Baumes erreicht ist, also die Auftrittswahrscheinlichkeit bei 1 liegt, ist die Huffman Codierung abgeschlossen. Jedem Zweig des Baums wird zusätzlich eine 0 oder 1 zugewiesen. In welchem Muster das geschieht, ist nicht wichtig und kann von Implementierung zu Implementierung abweichen. Wichtig ist nur zu beachten, dass dies im gesamten Baum konsistent durchgezogen wird (Linker Kindknoten 0, rechter Kindknoten 1 oder umgekehrt). Die Codewörter für jedes Symbol sind abzulesen, indem die Bitwerte der Zweige einander gereiht werden, beginnend von der Wurzel.

Um den Vorteil dieser Eigenschaft zu veranschaulichen, kann ein Vergleich mit dem *fixed length Code (FLC)* hilfreich sein. Anders als *Variable Length Code (VLC)* Verfahren wie die Huffman Codierung, wird jedem Symbol eines FLCs ein Codewort fester Länge zugewiesen. Die Auftrittswahrscheinlichkeit spielt bei der Erstellung von Codewörtern also keine Rolle. Um einen Vergleich zu ziehen kann die mittlere Codewortlänge des Alphabets, mit folgenden Symbolen betrachtet werden.

$S_i$	A	B	C	D
$P_i$	0.6	0.2	0.1	0.1

Die Formel zur Berechnung der mittleren Codewortlänge des FLCs lautet

$$\bar{l} = \lceil \log_2(N) \rceil$$

Wird das aus 4 Symbolen bestehende Beispielalphabet mittels FLC kodiert, ist die Codewortlänge  $l_i$  eines jeden Symbols = 2, wodurch auch die mittlere Codewortlänge bei 2,0 *Bits/Symbol* liegt.

Die Konstruktion des Binärbaums, aus dem die Codewörter entnommen werden können ist in Abb. 6 zu sehen.

Um die mittlere Codewortlänge einer Huffman Codierung zu berechnen, wird die Formel

$$\bar{l} = \sum_{i=1}^n p_i \cdot l_i$$

benötigt




Abb. 6: **Erstellen eines Huffman Codes** Die Abbildung zeigt die Konstruktion eines Binärbaums und der daraus resultierenden Codewörter für die Symbole

Aus dem Beispiel ergibt sich eine mittlere Codewortlänge von 1,6 *Bits/Symbol* bei einer Huffman Codierung. Im Vergleich zu einem FLC werden also 0,4 *Bits/Symbol* gespart.

Die Effektivität der Huffman Codierung nimmt ab, je balancierter der konstruierte Binärbaum ist. Im Umkehrschluss bedeutet das, dass eine Huffman Codierung sehr davon profitiert, dass einzelne Symbole eine höhere Auftretswahrscheinlichkeit besitzen als die anderen Symbole. Ändert sich jedoch die Statistik im Laufe der Anwendung, oder wurde diese vorab falsch berechnet, kann eine gute Kompression nicht mehr gewährleistet werden. Das bedeutet in einem Extremfall, dass einem Symbol ein sehr langes Codewort zugeteilt wurde, weil eine sehr geringe Auftretswahrscheinlichkeit berechnet wurde, die jedoch aus einer kleinen Teilmenge berechnet wurde, und somit nicht repräsentativ für den gesamten Kontext des Eingabestroms ist.

### 5.3 GZIP

Brotli-G misst sich mit anderen Kompressionsstandards wie GZip und Deflate. Der Deflate Algorithmus beschreibt eine Kombination aus dem LZ77 Algorithmus und der Huffman Codierung

### 5.4 Brotli-G Compute Shader

Das komprimierte Dreiecksnetz soll mittels Brotli-G's GPU Dekodierer dekodiert werden. Da Brotli-G mit der Grafik-API DirectX12 arbeitet, wird eine GPU benötigt die das Shader Model 6 unterstützt. Für die Verwendung des GPU Dekodierers wird also eine NVidia Grafikkarte mit der Turing-Architektur benötigt [Bur20]. Diese erkennt man am RTX Präfix vor der Modellnummer. Bei AMD Grafikkarten muss mindestens die RDNA-2 Architektur verbaut sein. Mit Grafikkarten

aus der AMD RX6000er Reihe für RDNA-2, und der RX7000er Reihe für RDNA-3 kann der GPU Dekodierer verwendet werden. Brotli-G definiert ihren GPU Dekodierer in der Shader-Sprache *high-level shader language (HLSL)* und ist als Compute Shader definiert (Kap. 2.4).

### 5.5 CPU Ebene

Queries Buffers etc

## 6 Ergebnisse

## **7 Fazit**

### **7.1 j...**

### **7.2 Ausblick**

## Literaturverzeichnis

- [Bro22] Brotli-G: An open-source compression/decompression standard for digital assets that is compatible with GPU hardware. In: *AMD GPUOpen* (2022). <https://gpuopen.com/brotli-g-sdk-announce/>
- [Bur20] BURGESS, John: RTX on—The NVIDIA Turing GPU. In: *IEEE Micro* 40 (2020), Nr. 2, S. 36–44. <http://dx.doi.org/10.1109/MM.2020.2971677>. – DOI 10.1109/MM.2020.2971677
- [Car22] CARVALHO, Miguel Ângelo Abreu d.: Exploring Mesh Shaders. (2022)
- [Com24] Compute Shader. In: *OpenGL Wiki* ((besucht am 09.02.2024)). [https://www.khronos.org/opengl/wiki/Compute\\_Shader](https://www.khronos.org/opengl/wiki/Compute_Shader)
- [CPP15] CHOUDHARY, Suman M. ; PATEL, Anjali S. ; PARMAR, Sonal J.: Study of LZ 77 and LZ 78 Data Compression Techniques, 2015
- [CR12] COZZI, P. ; RICCIO, C.: *OpenGL Insights*. Taylor & Francis, 2012 (Online access with subscription: Proquest Ebook Central). <https://books.google.de/books?id=CCVenzOGjpcC>. – ISBN 9781439893760
- [DC96] In: DAL CIN, Mario: *Klassifizierung von Rechnerarchitekturen*. Wiesbaden : Vieweg+Teubner Verlag, 1996. – ISBN 978-3-322-94769-7, 22–32
- [Ile22] In: ILETT, Daniel: *Advanced Shaders*. Berkeley, CA : Apress, 2022. – ISBN 978-1-4842-8652-4, 517–582
- [JBG17] JAKOB, Johannes ; BUCHENAU, Christoph ; GUTHE, Michael: A Parallel Approach to Compression and Decompression of Triangle Meshes using the GPU. In: *Computer Graphics Forum* 36 (2017), Nr. 5, 71-80. <http://dx.doi.org/https://doi.org/10.1111/cgf.13246>. – DOI <https://doi.org/10.1111/cgf.13246>
- [Kap23] KAPOULKINE, Arseny: Meshlet size tradeoffs. (2023). <https://zeux.io/2023/01/16/meshlet-size-tradeoffs/>
- [Kub18] KUBISCH, Christoph: Introduction to Turing Mesh Shaders. (2018). <https://developer.nvidia.com/blog/introduction-turing-mesh-shaders/#entry-content-comments>
- [Mic21] MICROSOFT: Typed Unordered Access Views (UAV). In: *Microsoft Documentation* (2021)



- [Mic23] MICROSOFT: LZ77 Compression Algorithm. In: *Microsoft Documentation* (2023). [https://learn.microsoft.com/en-us/openspecs/windows\\_protocols/ms-wusp/fb98aa28-5cd7-407f-8869-a6cef1ff1ccb](https://learn.microsoft.com/en-us/openspecs/windows_protocols/ms-wusp/fb98aa28-5cd7-407f-8869-a6cef1ff1ccb)
- [Mof19] MOFFAT, Alistair: Huffman Coding. In: *ACM Comput. Surv.* 52 (2019), aug, Nr. 4. <http://dx.doi.org/10.1145/3342555>. – DOI 10.1145/3342555. – ISSN 0360–0300
- [Zeu] ZEUX: meshoptimizer. <https://github.com/zeux/meshoptimizer>

# Ehrenwörtliche Erklärung

Ich versichere hiermit, dass ich meine Bachelorarbeit mit dem Titel

---

---

selbständig verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt sowie nicht an anderer Stelle als Prüfungsarbeit vorgelegt habe.

---

Ort

---

Datum

---

Unterschrift